Συγκριτική Αξιολόγηση Απόδοσης Μεγάλων Γλωσσικών Μοντέλων: Η Περίπτωση της Μελισσοκομίας

Ε-Ν. Καρέλα, Σ. Καρέτσος , Κ. Κωστοπούλου, Κ. Δεμέστιχας

Εργαστήριο Πληροφορικής, Τμήμα Αγροτικής Οικονομίας και Ανάπτυξης, Γεωπονικό Πανεπιστήμιο Αθηνών

ΕΙΣΑΓΩΓΗ

Τα Μεγάλα Γλωσσικά Μοντέλα (LLMs) αποτελούν καινοτόμα εργαλεία Τεχνητής Νοημοσύνης, ικανά να κατανοούν και να παράγουν φυσική γλώσσα με υψηλή ακρίβεια. Η χρήση τους επεκτείνεται σε εκπαίδευση, έρευνα και επαγγελματική υποστήριξη, ενισχύοντας τη διάχυση γνώσης. Η αξιολόγησή τους σε εξειδικευμένα πεδία, όπως η μελισσοκομία, προσφέρει ένα πρωτότυπο πλαίσιο για την κατανόηση των δυνατοτήτων και των ορίων τους.

ΣΚΟΠΟΣ

Συγκριτική αξιολόγηση της απόδοσης διαφορετικών Μεγάλων Γλωσσικών Μοντέλων (LLMs) μέσα από το παράδειγμα της μελισσοκομίας, με στόχο να αναδειχθούν τα πλεονεκτήματα, οι αδυναμίες και οι δυνατότητες εφαρμογής τους σε εξειδικευμένα γνωστικά πεδία. Συγκεκριμένα, αξιολογούνται τα LLaMA 3.2 3B Instruct, Qwen, Phi, DeepSeek, MiniOrca σε μελισσοκομικά καθήκοντα, συγκρίνοντας ακρίβεια και σαφήνεια.

ΜΕΘΟΔΟΛΟΓΙΑ

Τα επιλεγμένα μοντέλα εγκαταστάθηκαν στο σύστημα GPT4All και τροφοδοτήθηκαν με 13 βιβλία μελισσοκομικού περιεχομένου (3.008 σελίδες, με 914.215 λέξεις). Πραγματοποιήθηκε μετατροπή του corpus σε διανυσματικές αναπαραστάσεις, ανάγνωση των κειμένων, δημιουργία ευρετηρίου λέξεων και εξαγωγή των αντίστοιχων embeddings για κάθε λέξη. Τελικά δημιουργήθηκε το corpus πλήρως επεξεργασμένο και έτοιμο για περαιτέρω ανάλυση. Στη συνέχεια, τα βήματα ήταν τα ακόλουθα:

1ο Βήμα – Επιλογή ερωτήσεων

Επιλέχθηκαν 20 ερωτήσεις μελισσοκομίας:

•8 ερωτήσεις πολλαπλής επιλογής

•9 ερωτήσεις σωστού-λάθους

•3 ερωτήσεις ανάπτυξης

Οι ερωτήσεις μεταφράστηκαν από ελληνικά σε αγγλικά.

2ο Βήμα – Καθορισμός prompt

•Πολλαπλής επιλογής / Σωστού-Λάθους:

"What is the answer to the question '…' based on the following answers?"

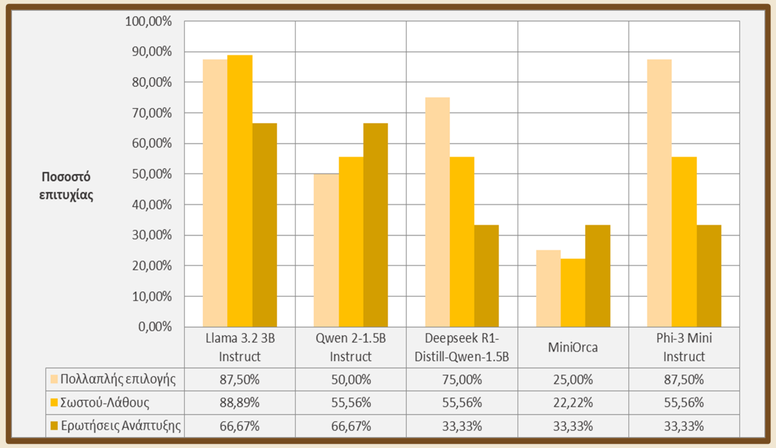
•Ανάπτυξης:

"What is the answer to the question '…'?»

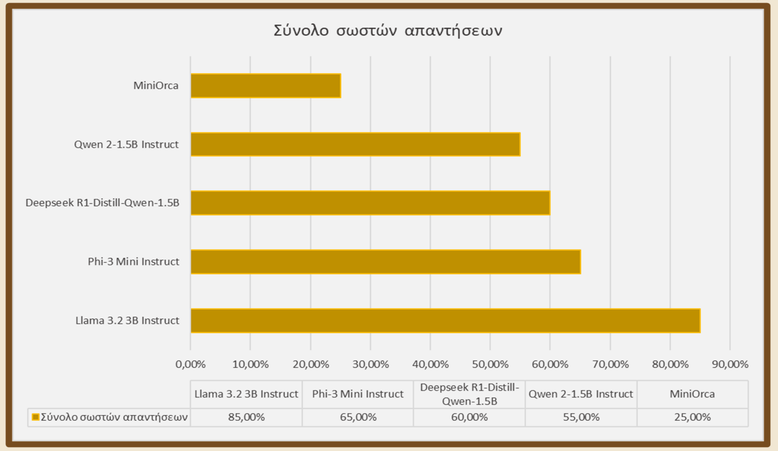
3ο Βήμα – Συλλογή και ανάλυση απαντήσεων

Οι απαντήσεις των LLMs συγκεντρώθηκαν και αξιολογήθηκαν ποιοτικά και ποσοτικά

ΑΠΟΤΕΛΕΣΜΑΤΑ



	Llama 3.2 3B Instruct	Qwen 2-1.5B Instruct	Deepseek R1-Distill-Qwen-1.5B	MiniOrca	Phi-3 Mini Instruct
Πολλαπλής επιλογής	87,50%	50,00%	75,00%	25,00%	87,50%
Σωστού-Λάθους	88,89%	55,56%	55,56%	22,22%	55,56%
Ερωτήσεις Ανάπτυξης	66,67%	66,67%	33,33%	33,33%	33,33%

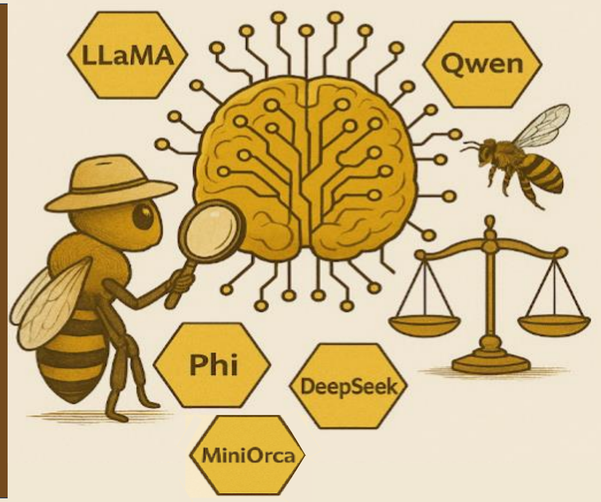


	Llama 3.2 3B Instruct	Phi-3 Mini Instruct	Deepseek R1-Distill-Qwen-1.5B	Qwen 2-1.5B Instruct	MiniOrca
Σύνολο σωστών απαντήσεων	85,00%	65,00%	60,00%	55,00%	25,00%

Το LLaMA 3.2 3B Instruct ξεχώρισε για υψηλή ακρίβεια, σταθερότητα και αξιόπιστη αιτιολόγηση σε όλες τις κατηγορίες ερωτήσεων, με συνολικό ποσοστό σωστών απαντήσεων **85%.** Τα υπόλοιπα μοντέλα ακολούθησαν με χαμηλότερη απόδοση, ενώ το τελευταίο έφτασε μόλις το 25%.

ΣΥΜΠΕΡΑΣΜΑΤΑ

- **Τα ερωτήματα που απαιτούν σύνθεση και αιτιολόγηση αποτέλεσαν πρόκληση για τα περισσότερα μοντέλα.**
- **Η απόδοση εξαρτάται από αρχιτεκτονική, ποιότητα εκπαίδευσης και ικανότητα παραγωγής τεκμηριωμένων απαντήσεων, όχι μόνο από ποσοστά ή παραμέτρους.**
- **Απαιτείται εκτενέστερη εκπαίδευση, πολυγλωσσικότητα, τεκμηρίωση και διαφάνεια πηγών.**
- **Η συνεργασία μεταξύ μοντέλων μπορεί να ενισχύσει ακρίβεια και αξιοπιστία.**
- **Τα LLMs ανοίγουν νέους δρόμους για την αγροτική και επιστημονική έρευνα, προσφέροντας τεκμηριωμένη γνώση και καινοτόμα εργαλεία για την πράξη.**



Ευχαριστίες: Αυτή η δημοσίευση αποτελεί μέρος του έργου TALLHEDA, το οποίο χρηματοδοτείται από το πρόγραμμα έρευνας και καινοτομίας Horizon Europe της Ευρωπαϊκής Ένωσης, βάσει της συμφωνίας επιχορήγησης αριθ. 101136578. Οι απόψεις και οι γνώμες που εκφράζονται είναι αποκλειστικά των συγγραφέων και δεν αντικατοπτρίζουν απαραίτητα τις απόψεις της Ευρωπαϊκής Ένωσης ή του Research Executive Agency (REA). Ούτε η Ευρωπαϊκή Ένωση ούτε η αρμόδια αρχή χορήγησης δύνανται να θεωρηθούν υπεύθυνες για αυτές.

TALLHEDA

Funded by the European Union